GP modellek III.

Fegyverneki Sándor Miskolci Egyetem Alkalmazott Matematikai Intézeti Tanszék matfs@uni-miskolc.hu

2021. február 22.



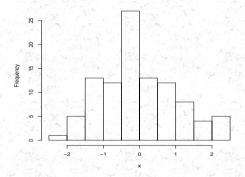
1 Bevezetés

- > x=rnorm(100)
- > hist(x)



Figure 1: A hisztogram

Histogram of x





2 ELOSZLÁSOK

Γ-ELOSZLÁS

$$\Gamma(\alpha+1) = \int_0^\infty t^\alpha e^{-t} dt$$

$$\Gamma(n+1) = n!, \quad \Gamma(1) = 1, \quad \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

$$f(x) = \frac{1}{\Gamma(\alpha)} \lambda^{\alpha} x^{\alpha - 1} e^{-\lambda x}, \quad \text{ha} \quad x > 0.$$

$$E(\xi) = \frac{\alpha}{\lambda}, \quad D^2(\xi) = \frac{\alpha}{\lambda^2}$$

Speciális esetek:

- 1. Exponenciális eloszlás: $\alpha = 1$.
- 2. χ_n^2 -eloszlás: $\alpha=\frac{n}{2},\ \lambda=\frac{1}{2}$



3 INTERVALLUMBECSLÉSEK

Véletlen intervallum – legalább az egyik végpontja valószínűségi változó.

Példa:
$$1 < \xi < 2 \iff 2 < 2\xi$$
 és $\xi < 2$

$$P(1 < \xi < 2) = P(\xi < 2 < 2\xi)$$

Példa: $\xi \sim \chi_{16}^2.$ Mennyi a valószínűsége, hogy $26.3 \in [\xi, 3.3\xi]?$

$$P(\xi < 26.3 < 3.3\xi) = P(7.97 < \xi < 26.3) \approx 0.90.$$

Az intervallum hossza: 2.3ξ .

Várható értéke: $E(2.3\xi) = 2.3 \cdot 16 = 36.8$.



FELADAT: az intervallum hossza ugyanolyan valószínűség mellett legyen rövid!!!

- kontrollkártyák (átlag, szórás, medián, mintaterjedelem)

Paraméter választás – feltételek, feladat. Mit akarunk ellenőrizni?

$$\theta \in \Theta$$
 – paramétertér: $\Theta_0 \subset \Theta$ és $P(\theta \in \Theta_0) = 1 - \alpha$
 $1 - \alpha$ megbízhatóságú konfidenciaintervallum (tartomány).

GP modellek Bevezetés FLOSZLÁSOK RVALLUMBEC Illeszkedésvizsgálat A Poisson-eloszlás s Vége Page 6 of 34 Full Screen Search Close

CSEBISEV-EGYENLŐTLENSÉG:

létezik $E(\xi)=m,\,D(\xi)=\sigma,\,$ ekkor

$$P(|\xi - m| \le k\sigma) \ge 1 - \frac{1}{k^2}.$$

$$E(\overline{\xi}) = m, \qquad D(\overline{\xi}) = \frac{\sigma}{\sqrt{n}}.$$

Minőségellenőrzés – 6σ , 8σ szabály.



Normális (GAUSS) eloszlás

$$\xi_1, \xi_2, \dots, \xi_n \sim N(m, \sigma^2)$$
, függetlenek

centrális határeloszlás-tétel (mintaelemszám> 30?)

FELADAT: $P(x_a < m < x_b) = 1 - \alpha$ – a σ_0 szórás ismert.

$$\frac{\overline{\xi} - m}{\sigma_0} \sqrt{n} \sim N(0, 1).$$

$$P\left(\overline{\xi} - u_{\frac{\alpha}{2}} \frac{\sigma_0}{\sqrt{n}} \le m \le \overline{\xi} + u_{\frac{\alpha}{2}} \frac{\sigma_0}{\sqrt{n}}\right) = 1 - \alpha,$$

ahol a σ_0 ismert és $\Phi(u_{\frac{\alpha}{2}}) = 1 - \frac{\alpha}{2}$.



FELADAT: $P(x_a < m < x_b) = 1 - \alpha$ — a σ szórás nem ismert.

$$\frac{\overline{\xi} - m}{s_n^{\star}} \sqrt{n} \sim t_{n-1}.$$

$$P\left(\overline{\xi} - t_{\frac{\alpha}{2}} \frac{s_n^\star}{\sqrt{n}} \le m \le \overline{\xi} + t_{\frac{\alpha}{2}} \frac{s_n^\star}{\sqrt{n}}\right) = 1 - \alpha,$$
 ahol az $F_n(t_{\frac{\alpha}{2}}) = 1 - \frac{\alpha}{2}.$



FELADAT: $P(x_a < \sigma^2 < x_b) = 1 - \alpha$.

$$\frac{ns_n^2}{\sigma^2} \sim \chi_{n-1}^2.$$

$$P\left(\frac{ns_n^2}{b} \le \sigma^2 \le \frac{ns_n^2}{a}\right) = 1 - \alpha,$$

$$x_1(a) = \frac{\alpha}{2} \quad \text{és} \quad \chi_{n-1}^2(b) = 1 - \frac{\alpha}{2}.$$

ahol a $\chi^2_{n-1}(a)=\frac{\alpha}{2}$ és $\chi^2_{n-1}(b)=1-\frac{\alpha}{2}$.



Exponenciális eloszlás

 $\xi_1, \xi_2, \dots, \xi_n \sim EXPO(\lambda)$, függetlenek

FELADAT:
$$P(x_a < \lambda < x_b) = 1 - \alpha$$

FELADAT:
$$P(x_a < \lambda < x_b) = 1 - \alpha$$

$$n\overline{\xi}\lambda \sim \Gamma_{n,1}, \quad P\left(\frac{a}{n\overline{\xi}} \le \lambda \le \frac{b}{n\overline{\xi}}\right) = 1 - \alpha,$$

ahol a $\Gamma_{n,1}(a) = \frac{\alpha}{2}$ és $\Gamma_{n,1}(b) = 1 - \frac{\alpha}{2}$.



ÁLTALÁNOS FORMULA

$$\xi_1,\xi_2,\dots,\xi_n\sim F_{ heta},$$
 függetlenek $-\sum_{i=1}^n \ln F_{ heta}(\xi_i)\sim \Gamma_{n,1}.$



4 Illeszkedésvizsgálat

Legyen az A_1,A_2,\ldots,A_k teljes eseményrendszer. Végezzünk el n Bernoulli-kísérletet a megfigyelésükre és jelölje Y_i az A_i gyakoriságát, ekkor az

$$(Y_1,Y_2,\ldots,Y_k)$$

vektor polinomiális eloszlású. Írjuk fel a következő hipotéziseket.

$$H_0 \quad : \quad p_i = p_i(\vartheta), \quad \text{ha} \quad \vartheta \in \Theta_0,$$

(1) H_1 : p_i tetszőleges.



Ekkor

(2)
$$2 \ln L(H_0, H_1) = 2 \sum_{i=1}^{k} Y_i \ln \hat{p}_i - 2 \sum_{i=1}^{k} Y_i \ln p_i(\hat{\vartheta}) = 0$$

$$=2\sum_{i=1}^{k}Y_{i}\ln\left(\frac{\hat{p}_{i}}{p_{i}(\hat{\vartheta})}\right),$$

ahol $\hat{p}_i = \frac{Y_i}{2}$ és $\hat{\vartheta}$ a ϑ maximum likelihood becslése a H_0

teljesülése esetén.

Vezessük be a következő jelöléseket:

(3)
$$o_i = Y_i, \quad e_i = np_i(\hat{\vartheta}), \quad \delta_i = o_i - e_i.$$



Ekkor

$$2\ln L(H_0, H_1) = 2\sum_{i=1}^{k} Y_i \ln \left(\frac{\hat{p}_i}{p_i(\hat{\vartheta})}\right)$$

$$=2\sum_{i=1}^{n} o_i \ln \left(\frac{o_i}{e_i}\right)$$

$$=2\sum_{i=1}^{k} (\delta_i + e_i) \ln \left(1 + \frac{\delta_i}{e_i}\right)$$

$$e_i$$
) $\ln\left(1+\frac{1}{e_i}\right)$

$$=2\sum_{i=1}^{k} (\delta_i + e_i) \sum_{m=1}^{\infty} (-1)^{m+1} \frac{\delta_i^m}{m e_i^m}$$

$$\approx \sum_{i=1}^{k} \frac{\delta_i^2}{e_i} = \sum_{i=1}^{k} \frac{(o_i - e_i)^2}{e_i}$$



(4)

Ez utóbbit szokás Pearson-féle χ^2 statisztikának nevezni, mert ha H_0 esetén $\vartheta \in \mathbf{R}^m$ és becsüljük, akkor

(5)
$$2 \ln L(H_0, H_1) \sim \chi_{k-m-1}^2$$

aszimptotikusan.

$$\chi^2 = \sum_{i=1}^k \frac{(o_i - e_i)^2}{e_i}$$

Ne felejtsük el k az intervallumok száma és m a becsült paraméterek száma.



Példa: Egy dobókocka dobálása során a következő gyakoriságokat kaptuk:

Ekkor

$$\chi^2 = \sum_{i=1}^6 \frac{(o_i - 40 \cdot \frac{1}{6})^2}{40 \cdot \frac{1}{6}}$$

(6)
$$\overline{X} = 3.275$$
, $\chi^2 = 4.1 < 11.071 \approx \chi^2_{5,0.05}$.

```
> qchisq(0.95,5)
[1] 11.0705
```



A Pearson-féle χ^2 -próba alkalmazható tetszőleges eloszlás vizsgálatára, azaz illeszkedésvizsgálatra. Adott az F eloszlásfüggvény. Osszuk fel a $(-\infty,+\infty)$ intervallumot. Legyen

(7)
$$-\infty = x_0 < x_1 < \cdots < x_k = +\infty,$$

(8)
$$p_i = F(x_{i+1}) - F(x_i), \quad (i = 1, 2, ..., k).$$

Megjegyzés:

A felosztás módjára nincs általános szabály. A szokásos alkalmazások: illeszkedésvizsgálat, függetlenség- és homogenitásvizsgálat.



Megjegyzés:

A hisztogram az alapstatisztikák közé tartozik, de csak most jutottunk el odáig, hogy a Pearson-féle χ^2 -próba kívánalmai szerint készítsük el.

Az [a, b] intervallum tartalmazza az adatokat.

(9)
$$a = d_0 < d_1 < \dots < d_k = b.$$

A felosztáskor figyeljük a darabszámot, kiugró értékeket és általában legyenek egyenlő hosszúak az intervallumok (kivéve a széleken). Adjuk meg a $[d_{i-1},d_i)$ intervallumba eső adatok számát (o_i) minden i-re. Az o_i gyakorisággal arányos oszlopot rajzolunk a $[d_{i-1},d_i)$ intervallumra.



Gyakorisághisztogram:

(10)
$$\sum_{i=1}^{n} \frac{o_i}{d_i - d_{i-1}} (d_i - d_{i-1}) = n.$$

Sűrűséghisztogram:

(11) $\sum_{i=1}^{\kappa} \frac{\overline{n}}{d_i - d_{i-1}} (d_i - d_{i-1}) = 1.$



```
> set.seed(135);z=rnorm(1000)
> cat("Atlag=", mean(z), "\n")
Atlag= -0.02837767
> cat("sn2=",(length(z)-1)/
length(z) *var(z), "\n")
sn2 = 1.0345
> cat ("Konf.szorasnegyzet",
(length(z)-1)*var(z)/
gchisq(0.975, length(z)-1), ", ",
(length(z)-1)*var(z)/qchisq(0.025,
length(z)-1), "\n")
Konf.szorasnegyzet
0.9504016 , 1.132704
> a=c(-6,-1.5,-0.5,0.5,1.5,6)
> p=vector()
> for (i in 1:(length(a)-1))
p[i] = pnorm(a[i+1]) - pnorm(a[i])
> np=length(z)*p
```



```
> z.cut=cut((z-mean(z))/sd(z),
breaks=a)
> nu=vector()
                                                         GP modellek
> for (i in 1: (length(a)-1))
                                                         Bevezetés
nu[i]=table(z.cut)[[i]]
                                                         FLOSZLÁSOK
                                                          JTERVALLUMBEC.
> chi2.z=sum((nu-np)^2/np)
                                                          lleszkedésvizsgálat
> cat ("p=",1-pchisq(chi2.z,length(a)-4),"
                                                         A Poisson-eloszlás s
p = 0.19279
                                                          Page 22 of 34
                                                           Full Screen
                                                             Search
                                                             Close
```

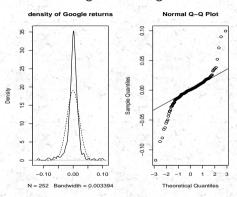
```
set.seed(135); ww=rnorm(10000)
> k=5
                                                    GP modellek
> q=seq(0,1,length.out = k+1)
                                                    Bevezetés
> a=vector()
                                                     FLOSZI ÁSOK
> for (i in 1:(k+1)) a[i]=gnorm(g[i])
                                                      eszkedésvizsgála
> p=vector()
                                                     A Poisson-eloszlás s
                                                     Vége
> for (i in 1:k) p[i]=1/k
                                                     Page 23 of 34
> np=length(ww)*p
> ww.cut=cut(((ww-mean(ww))/sd(ww)),
breaks=a)
> nu=vector()
> for (i in 1:k) nu[i]=table(ww.cut)[[i]]
> chi2.ww=sum((nu-np)^2/np)
                                                      Full Screen
> cat ("p=", 1-pchisq(chi2.ww, k-3), "\n")
                                                        Search
p = 0.2420769
                                                        Close
```

```
price=read.csv("c:/A_GP_munka/GOOG.csv")
#GOOG has 253 values
x <- diff(log(price[,6]))
par(mfrow=c(1,2))
plot(density(x),
main="density of Google returns")
z <- seq(min(x), max(x), length=201)
y <- dnorm(z, mean=mean(x), sd=sd(x))
lines(z,y,lty=2)
ggnorm(x)</pre>
```

qqline(x)



Figure 2: Google





5 A Poisson-eloszlás származtatása

Tekintsük a következő tulajdonságokkal rendelkező időben lejátszódó folyamatot: legyenek a bekövetkezések egymástól függetlenek, hosszú intervalumon az intenzitás egyenletes (a bekövetkezések várható száma $\lambda h,\ h$ az intervallum hossza), míg egységnyi intervallumon a várható számuk $\lambda>0$. Továbbá, nagyon kicsi δt intervallumon legfeljebb majdnem csak egyszer következik be.

Az o(g(x)) (kis ordó) jelölést alkalmazva folyamatunk matematikai modellje a következő:

$$o(g(x)) = h(x)$$
, ha $x \to a$, azt jelenti, hogy

$$\lim_{x \to a} \frac{h(x)}{g(x)} = 0.$$



Legyen $p_k(t) = P(\mbox{ pontosan } k \mbox{ darab bekövetkezés } t \mbox{ hosszúságú intervallumon}). Ekkor$

$$\begin{split} p_k(t+\delta t) &= p_k(t)p_0(\delta t) + p_{k-1}(t)p_1(\delta t) + \mathrm{o}(\delta t), \quad \text{ ha } k \geq 1, \\ p_0(t+\delta t) &= p_0(t)p_0(\delta t) + \mathrm{o}(\delta t). \end{split}$$

A kezdeti feltételek pedig

$$p_0(0) = 1, \qquad p_k(0) = 0, \quad \text{ ha } k \ge 1.$$

Továbbá, felírva nagyon kicsi intervallumra a folyamat tulajdonságait, a bekövetkezések várható száma alapján, a következő összefüggéseket kapjuk

$$p_1(\delta t) = \lambda \delta t + o(\delta t),$$

 $p_0(\delta t) = 1 - \lambda \delta t + o(\delta t).$

Ezeket behelyettesítve

 $p_k(t+\delta t) = p_k(t)(1-\lambda\delta t) + p_{k-1}(t)\lambda\delta t + \mathsf{o}(\delta t), \quad \text{ha } k \ge 1,$



$$p_0(t + \delta t) = p_0(t)(1 - \lambda \delta t) + o(\delta t).$$

Rendezzük át az egyenleteket:

$$\begin{split} \frac{p_k(t+\delta t)-p_k(t)}{\delta t} + \lambda p_k(t) &= \lambda p_{k-1}(t) + \mathrm{o}(1), \quad \text{ ha } k \geq 1, \\ \frac{p_0(t+\delta t)-p_0(t)}{\delta t} + \lambda p_0(t) &= \mathrm{o}(1). \end{split}$$

Ha $\delta t
ightarrow 0$, akkor

$$p_k'(t) + \lambda p_k(t) = \lambda p_{k-1}(t), \quad \text{ ha } k \ge 1,$$

$$p_0'(t) + \lambda p_0(t) = 0.$$

A második sorból rögtön adódik, hogy

$$\frac{d}{dt} \left[e^{\lambda t} p_0(t) \right] = 0,$$



$$e^{\lambda t}p_0(t) = p_0(0).$$

A $p_0(0)=1$ kezdeti feltétel szerint pedig $e^{\lambda t}p_0(t)=1$.

Hasonlóan a $k \ge 1$ esetekre

$$\frac{d}{dt} \left[e^{\lambda t} p_k(t) \right] = \lambda e^{\lambda t} p_{k-1}(t),$$

$$\left[e^{\lambda t}p_k(t)\right]_0^x = \int\limits_{\Omega} \lambda e^{\lambda t}p_{k-1}(t)dt.$$

A $p_k(0) = 0 \; (k \geq 1)$ kezdeti feltétel alapján

$$e^{\lambda x}p_k(x) = \int_{-\infty}^{x} \lambda e^{\lambda t}p_{k-1}(t)dt.$$



Vezessük be a $Q_k(x)=e^{\lambda x}p_k(x)$ jelölést, ekkor

$$Q_k(x) = \lambda \int_0^1 Q_{k-1}(t)dt, \quad \text{ ha } k \ge 1,$$

 $Q_0(x) = 1.$

Ebből rögtön adódik, hogy
$$Q_1(x) = \lambda \int\limits_0^x dt = \lambda x, \quad \text{azaz} \quad p_1(x) = \lambda x e^{-\lambda x};$$

$$Q_2(x) = \lambda \int\limits_0^x \lambda t dt = \frac{\lambda^2 x^2}{2}, \quad \text{azaz} \quad p_2(x) = \frac{\lambda^2 x^2}{2} e^{-\lambda x};$$

$$Q_3(x) = \lambda \int\limits_0^x \frac{\lambda^2 t^2}{2} dt = \frac{\lambda^3 x^3}{6}, \quad \text{azaz} \quad p_3(x) = \frac{\lambda^3 x^3}{6} e^{-\lambda x};$$



Általában pedig

$$Q_k(x) = \frac{\lambda^k x^k}{k!}, \quad \text{azaz} \quad p_k(x) = \frac{\lambda^k x^k}{k!} e^{-\lambda x}.$$

Végül egy rögzített t hosszúságú intervallumon, mivel a bekövetkezések várható száma $\mu=\lambda t,$ megkapjuk a Poisson-eloszlást.

$$P(\xi = k) = p_k(t) = \frac{\lambda^k t^k}{k!} e^{-\lambda t} = \frac{\mu^k}{k!} e^{-\mu}.$$



Köszönöm a figyelmet!



References

[1] Deák I.: Véletlenszámgenerátorok és alkalmazásaik, Akadémiai Kiadó, Budapest, 1986.

[FR11] Fegyverneki Sándor, Raisz Péter: Sztochasztikus modellezés, elektronikus jegyzet, 2011, TÁ-MOP 4.1.2-08/1/A-2009-0001 project, https://www.uni-miskolc.hu/~ matfs/

[FS11] Fegyverneki Sándor: Valószínűség-számítás és matematikai statisztika, elektronikus jegyzet, Kempelen Farkas elktronikus könyvtár, 2011, TÁMOP 4.1.2-08/1/A-2009-0001 project, https://www.uni-miskolc.hu/~ matfs/

[FE78] W. Feller: Bevezetés a valószínűségszámításba és alkalmazásaiba, Műszaki Könyvkiadó, Budapest. 1978.



[2] I.M. Szobol: A Monte-Carlo módszerek alapjai, Műszaki Könyvkiadó, Budapest, 1981.

