GP modellek IV.

Fegyverneki Sándor Miskolci Egyetem Alkalmazott Matematikai Intézeti Tanszék matfs@uni-miskolc.hu 2021. március 01.



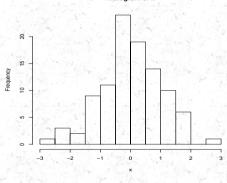
1 Bevezetés

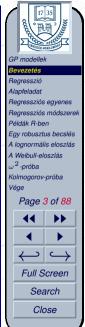
set.seed=139
x=rnorm(100)
hist(x)



Figure 1: A hisztogram

Histogram of x



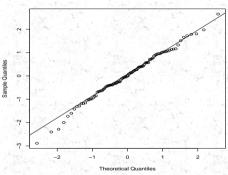


qqnorm(x)
qqline(x)



Figure 2: Pontok + egyenes

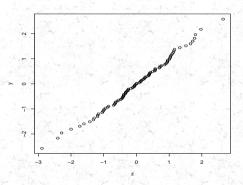






```
z = sort(x)
y=vector()
                                                                              GP modellek
for (i in 1:length(x))
                                                                              Bevezetés
                                                                              Regresszió
y[i] = qnorm((i-0.5)/length(x))
                                                                              Alapfeladat
plot(z, y)
                                                                              Regressziós egyenes
                                                                              Regressziós módszerek
                                                                              Példák R-ben
                                                                              Egy robusztus becslés
                                                                              A lognormális eloszlás
                                                                              A Weibull-eloszlás
                                                                              \omega^2-próba
                                                                              Kolmogorov-próba
                                                                               Véae
                                                                                 Page 6 of 88
                                                                                 Full Screen
                                                                                   Search
                                                                                    Close
```

Figure 3: Pontok (saját)

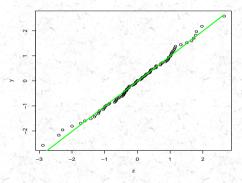


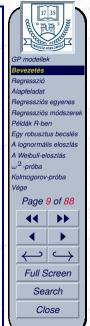


```
reg.curve.yz=lm( y ~ z)
lines(predict(reg.curve.yz)~z,
col="green", lwd=3)
```



Figure 4: Pontok + egyenes (saját)





```
summary (reg.curve.vz)
                                                           GP modellek
Call:
                                                           Bevezetés
                                                           Regresszió
lm(formula = v \sim z)
                                                           Alapfeladat
                                                           Regressziós egyenes
                                                           Regressziós módszerek
Residuals:
                                                           Példák R-hen
    Min 10 Median
                                                          Fav robusztus becslés
                                                          A lognormális eloszlás
          30 Max
                                                           A Weihull-eloszlás
-0.13898 - 0.04780 - 0.01391
                                                           ω<sup>2</sup>-próba
                                                           Kolmogorov-próba
0.01764 0.34996
                                                           Vége
                                                            Page 10 of 88
Coefficients:
                 Estimate Std. Error
                 t value Pr(>|t|)
                                                             \leftarrow
(Intercept) -0.018789 0.009242
                                                             Full Screen
-2.033 0.0448 *
               1.000879 0.009347
                                                              Search
 107.076 <2e-16 ***
                                                               Close
```

Signif. codes: 0 *** 0.001 **
0.01 * 0.05 . 0.1 ' ' 1

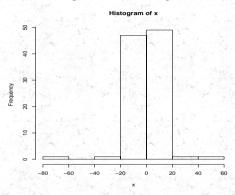
Residual standard error: 0.0924 on 98 degrees of freedom Multiple R-squared: 0.9915, Adjusted R-squared: 0.9914 F-statistic: 1.147e+04 on 1 and 98 DF, p-value: < 2.2e-16

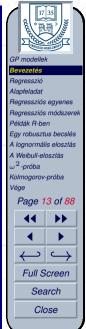


set.seed=139
x=rcauchy(100)
hist(x)



Figure 5: A hisztogram



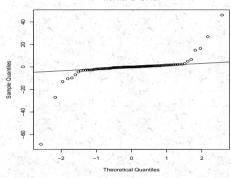


qqnorm(x)
qqline(x)



Figure 6: Pontok + egyenes







```
z=sort(x)
y=vector()
for (i in 1:length(x))
y[i]=qcauchy((i-0.5)/length(x))
plot(z,y)
```

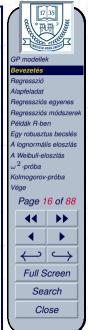
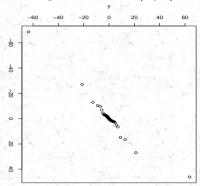


Figure 7: Pontok (saját)

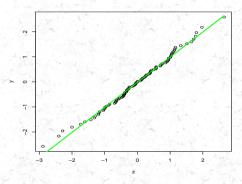


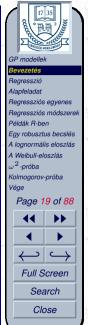


```
reg.curve.yz=lm( y ~ z)
lines(predict(reg.curve.yz)~z,
col="green", lwd=3)
```



Figure 8: Pontok + egyenes (saját)



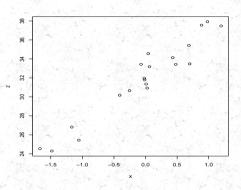


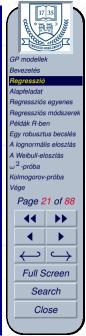
2 Regresszió

```
set.seed(38)
n=20
a=32;b=5
x=rnorm(n);epsilon=rnorm(n)
z=a+b*x+epsilon
plot(x,z)
```



Figure 9: Regresszió





3 Alapfeladat

Adott $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n).$

Keressük azt a függvényt,

$$y = g(x),$$

amelyre

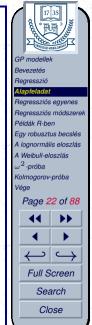
$$Q(g) = \sum_{i=1}^{K} (y_i - g(x_i))^2$$

minimális.

Ez azt jelenti, hogy minimalizáljuk az

$$\varepsilon_i = y_i - g(x_i)$$

véletlennek tekintett rezidumok négyzetösszegét.



Általános feladat:

X és Y valószínűségi változók. Keressük azt a g valós függvényt, amelyre

$$\min_{g} E((Y - g(X))^2).$$

Megoldás a feltételes várható érték:

$$E(Y|X=x).$$



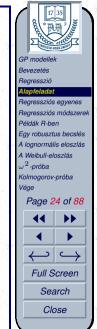
Diszkrét eset:

$$E(Y|X=x_i) = \sum_{j=1}^{\infty} y_j \frac{p_{ij}}{q_i}$$

Folytonos eset:

$$E(Y|X=x) = \int_{-\infty}^{\infty} y f_{Y|X}(y|x) dy = m_1(x)$$

A függvényt az Y-nak az X-re vonatkozó regressziós függvényének nevezzük.



Normális eloszlás

$$(X,Y) \sim N(m_1, m_2, {\sigma_1}^2, {\sigma_2}^2, \rho).$$

ekkor

$$m_1(x) = m_2 + \rho \frac{\sigma_2}{\sigma_1} (x - m_1),$$

 $m_2(y) = m_1 + \rho \frac{\sigma_1}{\sigma_2} (y - m_2).$

Tehát a regressziós függvények egyenesek.



4 Regressziós egyenes

A regressziós egyenes meghatározása: Adott (x_1, y_1) , $(x_2, y_2), \ldots, (x_n, y_n)$. Keressük azt az egyenest,

$$y = bx + a$$
,

amelyre

$$Q(a,b) = \sum_{i=1}^{n} (y_i - bx_i - a)^2$$

minimális. Ez azt jelenti, hogy minimalizáljuk az $\varepsilon_i=y_i-bx_i-a$ véletlennek tekintett rezidumok négyzetösszegét.

Vezessük be a következő jelöléseket:

$$\overline{x} = \frac{\sum_{i=1}^{n} x_i}{n}, \quad \overline{y} = \frac{\sum_{i=1}^{n} y_i}{n},$$



$$Q_x = \sum_{i=1}^{n} x_i^2 - n\overline{x}^2, \quad Q_y = \sum_{i=1}^{n} y_i^2 - n\overline{y}^2, \quad Q_{xy} = \sum_{i=1}^{n} x_i y_i - n\overline{y}^2$$

Ekkor a regressziós egyenes együtthatói
$$b_{yx} = \frac{Q_{xy}}{Q_x}, \quad a_{yx} = \overline{y} - b_{yx}\overline{x}.$$
 A hibák, a konfidencia-intervallumok és a hipotézisvizsgálatok leírásához bevezetett jelölésekben az s a korrigált tapasztalati szórásra utal.
$$Q_{y.x} = Q_y - b_{yx}Q_{xy} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = Q(a_{yx}, b_{yx}),$$

$$r = \frac{Q_{xy}}{\sqrt{Q_xQ_y}}, \quad s_x^2 = \frac{Q_x}{n-1}, \quad s_y^2 = \frac{Q_y}{n-1}, \quad s_{xy}^2 = \frac{Q_{xy}}{n-1},$$

$$s_{yx}^2 = \frac{Q_{yx}}{n-1}, \quad s_{yy}^2 = \frac{Q_{xy}}{n-1}, \quad s_{xy}^2 = \frac{Q_{xy}}{n-1},$$

$$s_{yx}^2 = \frac{Q_{yx}}{n-2}, \quad s_{yy}^2 = \frac{Q_{yx}}{n-2}, \quad s_{yy}^2 = \frac{Q_{xy}}{n-1},$$
 Search Close

Két egyenes összehasonlítása: Adott két minta. A mintaelemszámok n és m. A formulákban az 1 illetve 2 indexek az aktuális mintára utalnak. A b_1 és b_2 regressziós együtthatók összehasonlításához először végezzük el a következő F-próbát:

$$\frac{s_{y_1.x_1}^2}{s_{y_2.x_2}^2} > F_{(n-2,m-2;0.05)}.$$

A további lépéseinket az F-próba alapján két irányba folytathatjuk:

1. Ha az F-próba elfogad, azaz feltehetjük, hogy a szórásnégyzetek megegyeznek, akkor a

$$\hat{t} = \frac{b_1 - b_2}{\sqrt{\frac{Q_{y_1.x_1} + Q_{y_2.x_2}}{n + m - 4} \left[\frac{1}{Q_{x_1}} + \frac{1}{Q_{x_2}}\right]}}$$



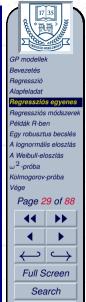
statisztika közelítőleg Student-eloszlású n+m-4 szabadságfokkal.

2. Ha az F-próba elutasít, azaz feltehetjük, hogy a szórásnégyzetek különböznek, akkor elég nagy minták esetén (n>20,m>20) a

$$= \frac{b_1 - b_2}{\sqrt{\frac{s_{y_1.x_1}^2}{Q_{x_1}} + \frac{s_{y_2.x_2}^2}{Q_{x_2}}}}$$

statisztika közelítőleg Student-eloszlású ν szabadságfokkal, ahol

$$\nu = \frac{1}{\frac{c^2}{n-2} + \frac{(1-c)^2}{m-2}} \quad \text{és} \quad c = \frac{\frac{s_{y_1.x_1}^2}{Q_{x_1}}}{\frac{s_{y_1.x_1}^2}{Q_{x_1}} + \frac{s_{y_2.x_2}^2}{Q_{x_2}}}, \quad n \leq m.$$



Close

Regressziós egyenesekre vonatkozóan sokszor csupán ezt a párhuzamossági kérdést vizsgálják. Ha elfogadtuk a párhuzamossági hipotézist, akkor a regressziós együttható most már a két minta adataiból a következőképpen becsülhető: Hátra van még az egyenesek azonosságára vonatkozó döntés kérdése. Ezt további két részre kell bontanunk.

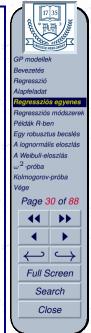
1. Ha $\overline{x}_1 \neq \overline{x}_2$, akkor a közös regressziós együttható megadható

$$\frac{\overline{y}_2 - \overline{y}_1}{\overline{x}_2 - \overline{x}_1}$$

formában is.

2. Ha $\overline{x}_1=\overline{x}_2$, akkor az $\overline{y}_1=\overline{y}_2$ biztosítja a regressziós egyenesek azonosságát, így azt kell megvizsgálnunk. A szokásos kétmintás t-próba alkalmas ennek eldöntésére.

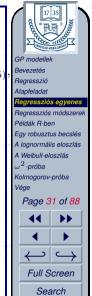
Ha nem szükséges a párhuzamosság, akkor közvetlenül al-



kalmazható a következő F-próba:

$$\hat{F} = \frac{n+m-4}{2} \frac{Q_{y.x;T} - Q_{y_1.x_1} - Q_{y_2.x_2}}{Q_{y_1.x_1} + Q_{y_2.x_2}} > F_{(2,n+m-4;0.05)}$$

ahol $Q_{y.x;T}$ az egyesített mintára vonatkozó érték.



Close

5 Regressziós módszerek

Elsőként tekintsük a többszörös lineáris regressziót. Ez nem más, mint az egyszerű lineáris regresszió általánosítása arra az esetre, amikor legalább két magyarázó változó van. Legyen

$$g(\xi_1, \xi_2, \dots \xi_k) = \beta_0 + \beta_1 \xi_1 + \dots + \beta_k \xi_k$$

a többszörös regresszió egyenlete, ahol $\xi_1,\xi_2,\ldots\xi_k$ a k darab független (magyarázó) változó, amelyek kapcsolódnak az η (függő) változóhoz. Az adatok

$$(Y_i, X_{i1}, \dots, X_{ik}), \quad i = 1, 2, \dots, n,$$

egy (k+1)-dimeziós tér pontjainak tekinthető. A

$$\beta_i, \quad i = 0, 1, \dots, k,$$



a regressziós együttható. Egyenként nincs jelentésük viszont együtt fontos szerepet játszanak az η értékeinek előrejelzésében. Legyen

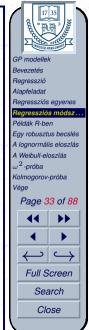
$$X = \begin{pmatrix} 1 & X_{11} & \dots & X_{1k} \\ 1 & X_{21} & \dots & X_{2k} \\ & \ddots & \ddots & \vdots & \ddots \\ 1 & X_{n1} & \dots & X_{nk} \end{pmatrix}$$

Jelölje E(Z) a várható értékek mátrixát a Z mátrix elemeihez. Feltesszük, hogy

$$E(Y) = X\beta,$$

ahol $\beta^T=(\beta_0,\beta_1,\ldots\beta_k)$. Legyen $\varepsilon=Y-E(Y)$. ε elemeit rezidumoknak nevezzük. Ekkor

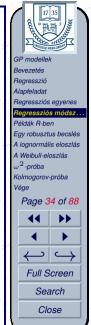
$$Y = X\beta + \varepsilon, \quad E(\varepsilon) = 0.$$



Ha X^TX nemszinguláris, akkor a regressziós módszerek lényege a következő eredményekben foglalható össze:

- 1. A $b=(X^TX)^{-1}X^TY$ a legkisebb négyzetes paraméterbecslés a β vektorra.
- 2. A $b=(X^TX)^{-1}X^TY$ a β maximum-likelihood becslése, ha Y n-dimenziós normális eloszlású.
- 3. $E(b) = \beta$.
- 4. Legyen $cov(Y) = \sigma^2 I$, akkor $cov(b) = \sigma^2 (X^T X)^{-1}$. I az egységmátrix.
- 5. Ha Y normális eloszlású, akkor $b\ (k+1)$ -dimenziós normális eloszlású.
- 6. Normalitást feltételezve a σ^2 maximum-likelihood becslése

$$\tilde{\sigma}^2 = \frac{Y^T [I - X(X^T X)^{-1} X^T] Y}{n}.$$



7.
$$E(\tilde{\sigma}^2) = (n - k - 1)\sigma^2/n$$
, így

$$\hat{\sigma}^2 = \frac{Y^T [I - X(X^T X)^{-1} X^T] Y}{n - k - 1}$$

a σ^2 torzítatlan becslése.

8. Ha
$$\,Y\,$$
 normális eloszlású, akkor

$$\frac{(n-k-1)\hat{\sigma}^2}{\sigma^2} = \frac{Y^T[I-X(X^TX)^{-1}X^T]Y}{\sigma^2} \sim \chi^2_{n-k-1}.$$

- 9. $b \in \hat{\sigma}^2$ függetlenek.
- 10. Bármely $h^T\beta$ lineáris kombinációra (ha nincs normalitás akkor is) a h^Tb minimális szórásnégyzetű lineáris torzítatlan becslés.

Hipotézisvizsgálat: Normalitás feltételezése esetén

$$\frac{h^T b - h^T \beta}{s_{h^T h}} \sim t_{n-k-1},$$



Alanfeladat

Regressziós egyenes Regressziós módsz

Példák R-hen

Peldák R-ben Eav robusztus becslés

A lognormális eloszlás A Weibull-eloszlás ω²-próba

Page 35 of 88

Kolmogorov-próba





Search
Close

azaz Student-eloszlású, ahol $s_{h^Th}=\sqrt{\hat{\sigma}^2h^T(X^TX)^{-1}h}.$ A $h^T\beta=a$ hipotétis vizsgálatára a

$$t = \frac{h^T b - a}{s_{h^T h}}$$

teszt statisztika éppen megfelelő. Sőt ez alapján $h^T\beta$ értékére konfidenciaintervallum készíthető.

Az illesztett egyenlet minőségének a vizsgálata az előzőek alapján. Néhány használatos mérőszám.

A rezidumok négyzeteinek az összege

$$RSS = \sum_{i=1}^{n} (Y_i - \hat{Y}_i)^2.$$

Az \overline{Y} átlagtól való négyzetes eltérések teljes összege

$$TSS = \sum_{i=1}^{n} (Y_i - \overline{Y})^2.$$



Népszerű még a négyzetes többszörös korrelációs együttható

$$R^2 = 1 - \frac{RSS}{TSS}.$$

Erre teljesül, hogy $0 \le R^2 \le 1$, és azt szokás mondani, ha közel van egyhez akkor jó az illeszkedés.

Vigyázat RSS és TSS direkten nem összehasonlíthatók, hiszen az egyik esetben csak egy míg a másik esetben (k+1) paramétert becsültünk.

Egy másik mérőszám sorozat az előző négyzetek átlaga (a torzítatlanság figyelembe vétele):

$$RMS = \frac{RSS}{n-k-1}, \quad TMS = \frac{TSS}{n-1}, \quad R_a^2 = 1 - \frac{RMS}{TMS},$$

ahol R_a^2 az ún. korrigált ("adjusted") R^2 .

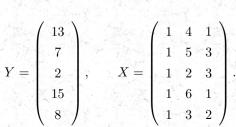
Példa:



Adottak a következő megfigyelési adatok.

Y	Λ_1	Λ_2
13	4	1
7	5	3
2	2	3
15	6	1
8	3	2

Ekkor





Alapfeladat Regressziós egyenes

Regressziós módsz... Példák R-ben Egy robusztus becslés A lognormális eloszlás

A Weibull-eloszlás ω^2 -próba Kolmogorov-próba Véae





Search Close

$$X^T X = \left(\begin{array}{ccc} 5 & 20 & 10 \\ 20 & 90 & 37 \\ 10 & 37 & 34 \end{array}\right),$$

$$(X^T X)^{-1} = \begin{pmatrix} 5.103 & -0.710 & -1.032 \\ -0.710 & 0.129 & 0.097 \\ -1.032 & 0.097 & 0.323 \end{pmatrix},$$

$$X^TY=\begin{pmatrix}45\\205\\71\end{pmatrix},\quad b=\begin{pmatrix}10.871\\1.387\\-3.710\end{pmatrix},\quad \hat{\sigma}^2=0.419.$$
 Ha meg akarjuk vizsgálni a $H_0:\beta_1=\beta_2$ hipotézist, ekkor a $h^T=(0,1,-1)$ választással ez átírható a $H_0:h^T\beta=0$ hipotézissé. Viszont

ipotézissé. Viszont
$$s_{h^Th}^2 = 0.1081, \quad \text{azaz} \quad t = \frac{h^Tb}{s_{h^Th}} = \frac{5.097}{0.3288} = 15.5,$$



amelyből következik H_0 elutasítása, hiszen a kritikus érték 0.95-ös szinten 2.35.

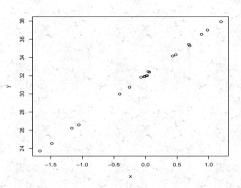


6 Példák R-ben

```
set.seed(38)
n=20
a=32;b=5
x=rnorm(n);epsilon=rnorm(n)
y=a+b*x+0.1*epsilon
plot(x,y)
```



Figure 10: Regresszió

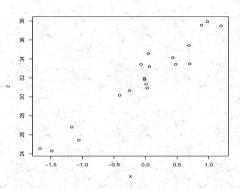




```
set.seed(38)
n=20
a=32;b=5
x=rnorm(n);epsilon=rnorm(n)
z=a+b*x+epsilon
plot(x,z)
```



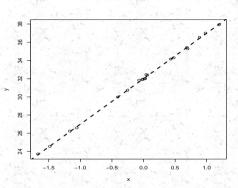
Figure 11: Regresszió





```
set.seed(38)
n = 2.0
                                                                         GP modellek
a=32;b=5
                                                                         Bevezetés
                                                                         Regresszió
x=rnorm(n);epsilon=rnorm(n)
                                                                         Alapfeladat
y=a+b*x+0.1*epsilon
                                                                         Regressziós egyenes
                                                                         Regressziós módszerek
plot(x, y)
                                                                         Példák R-ben
abline(a,b, lty=2, lwd=3)
                                                                        Eav robusztus becslés
                                                                        A lognormális eloszlás
                                                                        A Weibull-eloszlás
abline (lm(y\sim x), col="red", lwd=3)
                                                                        ω<sup>2</sup> -próba
                                                                         Kolmogorov-próba
                                                                         Véae
                                                                          Page 45 of 88
                                                                           Full Screen
                                                                             Search
                                                                              Close
```

Figure 12: Regresszió





```
summary(lm(v~x))
                                                        GP modellek
Call:
                                                        Revezetés
                                                        Regresszió
lm(formula = v \sim x)
                                                         Alapfeladat
                                                        Regressziós egyenes
                                                        Regressziós módszerek
Residuals:
                                                        Példák R-ben
       Min
              10 Median
                                                        Fav robusztus becslés
                                                        A lognormális eloszlás
               30
                    Max
                                                        A Weihull-eloszlás
-0.204676 -0.056521 -0.005408
                                                        ω<sup>2</sup>-próba
                                                        Kolmogorov-próba
         0.070688 0.226248
                                                         Vége
                                                          Page 47 of 88
Coefficients:
               Estimate Std. Error
               t value Pr(>|t|)
                                                          (Intercept) 32.00867 0.02460
                                                           Full Screen
1301.0 <2e-16 ***
         4.99216 0.03142
                                                            Search
158.9 <2e-16 ***
                                                            Close
```

Signif. codes: 0 '***' 0.001
'**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

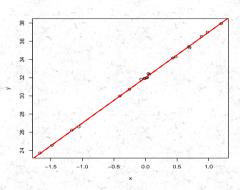
Residual standard error: 0.1099

on 18 degrees of freedom
Multiple R-squared: 0.9993,
Adjusted R-squared: 0.9992
F-statistic: 2.525e+04 on 1 and 18 DF,
p-value: < 2.2e-16



```
set.seed(38)
n = 2.0
                                                                         GP modellek
a=32;b=5
                                                                         Bevezetés
                                                                         Regresszió
x=rnorm(n);epsilon=rnorm(n)
                                                                         Alapfeladat
z=a+b*x+epsilon
                                                                         Regressziós egyenes
                                                                         Regressziós módszerek
plot(x,z)
                                                                         Példák R-ben
abline(a,b, lty=2, lwd=3)
                                                                         Eav robusztus becslés
                                                                         A lognormális eloszlás
                                                                         A Weibull-eloszlás
abline (lm(z\sim x), col="red", lwd=3)
                                                                         ω<sup>2</sup> -próba
                                                                         Kolmogorov-próba
                                                                         Véae
                                                                           Page 49 of 88
                                                                            Full Screen
                                                                             Search
                                                                              Close
```

Figure 13: Regresszió





```
summary(lm(z~x))
                                                          GP modellek
Call:
                                                          Revezetés
                                                          Regresszió
lm(formula = z \sim x)
                                                          Alapfeladat
                                                          Regressziós egyenes
                                                          Regressziós módszerek
Residuals:
                                                          Példák R-ben
      Min 10 Median
                                                         Fav robusztus becslés
                                                         A lognormális eloszlás
            30 Max
                                                          A Weihull-eloszlás
-2.04676 - 0.56521 - 0.05408
                                                         \omega^2-próba
                                                         Kolmogorov-próba
0.70688 2.26248
                                                          Vége
                                                           Page 51 of 88
Coefficients:
               Estimate Std. Error
               t value Pr(>|t|)
                                                            (Intercept) 32.0867 0.2460
                                                            Full Screen
130.42 < 2e-16 ***
                  4.9216 0.3142
                                                             Search
15.66 6.22e-12 ***
                                                              Close
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.099 on 18 degrees of freedom Multiple R-squared: 0.9317, Adjusted R-squared: 0.9279

F-statistic: 245.4 on 1 and 18 DF.

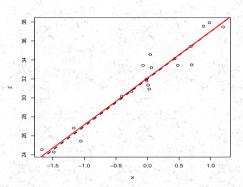
p-value: 6.222e-12



Close

```
set.seed(38)
                                                                         GP modellek
n = 2.0
                                                                         Bevezetés
                                                                         Regresszió
a=32:b=5
                                                                         Alapfeladat
x=rnorm(n);epsilon=rnorm(n)
                                                                         Regressziós egyenes
                                                                         Regressziós módszerek
y=a+b*x+epsilon
                                                                         Példák R-ben
plot(x, y)
                                                                         Egy robusztus becslés
                                                                         A lognormális eloszlás
abline(a,b, lty=2, lwd=3)
                                                                         A Weibull-eloszlás
                                                                          ω<sup>2</sup> -próba
                                                                         Kolmogorov-próba
abline (lm(y\sim x), col="red", lwd=3)
                                                                          Véae
                                                                           Page 53 of 88
                                                                            Full Screen
                                                                              Search
                                                                               Close
```

Figure 14: Regresszió





```
summary(lm(y~x))
                                                            GP modellek
Call:
                                                            Bevezetés
                                                            Regresszió
lm(formula = v \sim x)
                                                            Alapfeladat
                                                            Regressziós egyenes
                                                            Regressziós módszerek
Residuals:
                                                            Példák R-ben
    Min 10 Median
                                                            Fay robusztus becslés
                                                            A lognormális eloszlás
           30 Max
                                                            A Weibull-eloszlás
-10.2338 -2.8261 -0.2704
                                                            ω<sup>2</sup>-próba
                                                            Kolmogorov-próba
3.5344 11.3124
                                                            Véae
                                                              Page 55 of 88
Coefficients:
               Estimate Std. Error
                t value Pr(>|t|)
                                                              \leftarrow \rightarrow
(Intercept) 32.434 1.230
                                                               Full Screen
26.366 7.8e-16 ***
                                  1.571
                                                                Search
                   4.608
2.934 0.00888 **
                                                                 Close
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

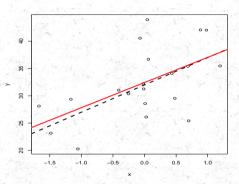
Residual standard error: 5.497 on 18 degrees of freedom
Multiple R-squared: 0.3234,
Adjusted R-squared: 0.2859
F-statistic: 8.605 on 1 and 18 DF,

p-value: 0.008878



```
set.seed(38)
n = 2.0
                                                                         GP modellek
a=32;b=5
                                                                         Bevezetés
                                                                         Regresszió
x=rnorm(n);epsilon=rnorm(n)
                                                                         Alapfeladat
y=a+b*x+5*epsilon
                                                                         Regressziós egyenes
                                                                         Regressziós módszerek
plot(x, y)
                                                                         Példák R-ben
abline(a,b, lty=2, lwd=3)
                                                                         Eav robusztus becslés
                                                                         A lognormális eloszlás
                                                                         A Weibull-eloszlás
abline (lm(y\sim x), col="red", lwd=3)
                                                                         ω<sup>2</sup> -próba
                                                                         Kolmogorov-próba
                                                                         Véae
                                                                           Page 57 of 88
                                                                            Full Screen
                                                                             Search
                                                                              Close
```

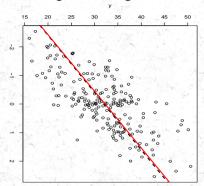
Figure 15: Regresszió





```
set.seed(38)
n = 2.00
                                                                         GP modellek
a=32; b=5
                                                                         Bevezetés
                                                                         Regresszió
x=rnorm(n);epsilon=rnorm(n)
                                                                         Alapfeladat
y=a+b*x+5*epsilon
                                                                         Regressziós egyenes
                                                                         Regressziós módszerek
plot(x, y)
                                                                         Példák R-ben
abline(a,b, lty=2, lwd=3)
                                                                         Eav robusztus becslés
                                                                         A lognormális eloszlás
                                                                         A Weibull-eloszlás
abline (lm(y\sim x), col="red", lwd=3)
                                                                         ω<sup>2</sup> -próba
                                                                         Kolmogorov-próba
                                                                         Véae
                                                                           Page 59 of 88
                                                                            Full Screen
                                                                             Search
                                                                              Close
```

Figure 16: Regresszió





```
summary(lm(y~x))
                                                            GP modellek
Call:
                                                            Bevezetés
                                                            Regresszió
lm(formula = v \sim x)
                                                            Alapfeladat
                                                            Regressziós egyenes
                                                            Regressziós módszerek
Residuals:
                                                            Példák R-ben
    Min 10 Median
                                                            Fay robusztus becslés
                                                            A lognormális eloszlás
            30 Max
                                                            A Weihull-eloszlás
-12.3088 \quad -3.5666 \quad -0.7507
                                                            \omega^2-próba
                                                            Kolmogorov-próba
3.6359 13.6598
                                                             Véae
                                                              Page 61 of 88
Coefficients:
               Estimate Std. Error
                t value Pr(>|t|)
                                                              \leftarrow \rightarrow
(Intercept) 32.2465 0.3562
                                                               Full Screen
90.52 <2e-16 ***
                  5.0534 0.3700
                                                                Search
13.66 <2e-16 ***
                                                                 Close
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.034 on 198 degrees of freedom
Multiple R-squared: 0.485,
Adjusted R-squared: 0.4824

F-statistic: 186.5 on 1 and 198 DF,

p-value: < 2.2e-16

GP modellek Revezetés Regresszió Alapfeladat Regressziós egyenes Regressziós módszerek Példák R-ben Fav robusztus becslés A lognormális eloszlás A Weihull-eloszlás ω²-próba Kolmogorov-próba Véae Page 62 of 88 Full Screen Search Close

Egy robusztus becslés

Két eloszlást azonos típusúnak nevezünk, ha léteznek a és b>0 valós számok, amelyre

$$F(x) = G(bx + a),$$

ahol F és G a megfelelő eloszlásfüggvények.

Ez a típus definíció egy osztályozást határoz meg az eloszlások halmazán. Válasszunk ki egy osztályt és legyen ennek egy reprezentánsa F_0 , ekkor az osztály egy tetszőleges elemére igaz, hogy létezik a és b>0 valós szám, amelyre

$$F(x) = F_0\left(\frac{x-a}{b}\right).$$



Megjegyzés:

1. Ha a ξ valószínűségi változó eloszlásfüggvénye F_0 és az η eloszlásfüggvénye F, akkor

$$n = b\xi + a$$
.

2. Az így adódó a illetve b értéket hely- illetve skálaparaméternek nevezzük.



A hely- és skálaparaméter becslésére vonatkozó feladatot a következőképpen fogalmazhatjuk meg:

Adott a $\xi_1, \xi_2, \ldots, \xi_n$ minta, amely elemeinek közös eloszlásfüggvénye F, amelyről tudjuk, hogy az F_0 eloszlásfüggvénnyel reprezentált osztályhoz tartozik. Határozzuk meg az F eloszlásfüggvényt, azaz azokat az a illetve b>0 értékeket, amelyre teljesül

Ekkor az eloszlásfüggvények tulajdonságai alapján felírhatók a következő egyenlőségek:

$$\int_{-\infty}^{+\infty} \left(F_0 \left(\frac{x-a}{b} \right) - 0.5 \right) dF_0(x) = 0$$

$$\int_{-\infty}^{+\infty} \left(F_0 \left(\frac{x-a}{b} \right) - 0.5 \right)^2 dF_0(x) = \frac{1}{12}.$$



A Monte Carlo módszerek elmélete (a nagy számok erős törvénye) alapján az egyenlőségekből következik, hogy

$$\frac{1}{n} \sum_{k=1}^{n} \left(F_0 \left(\frac{x-a}{b} \right) - 0.5 \right) \cong 0$$

$$\frac{1}{n}\sum_{k=1}^{n} \left(F_0\left(\frac{x-a}{b}\right) - 0.5 \right)^2 \cong \frac{1}{12}.$$

A relációkat egyenlőségként tekintve kapunk egy egyenletrendszert az a és b ismeretlenekre. Az egyenletrendszert a következő algoritmussal oldhatjuk meg.

Jelölje az a illetve b közelítését (becslését) a m-edik iterációs lépésben $\vartheta_n^{(m)}$ illetve $s_n^{(m)}$. Ekkor legyen

$$\vartheta_n^{(0)} = med\{\xi_i\},$$

$$s_n^{(0)} = MAD\{\xi_i\},$$



ahol $med\{\xi_i\}$ a minta mediánja és

$$MAD\{\xi_i\} = med\{|\xi_i - med\{\xi_i\}|\}$$

pedig a medián abszolút eltérés.

Az algoritmus iterációs lépései a következők:

$$\vartheta_n^{(k+1)} = \vartheta_n^{(k)} + \frac{s_n^{(k)} \sum_{i=1}^n \psi\left(\frac{\xi_i - \vartheta_n^{(k)}}{s_n^{(k)}}\right)}{n}$$

$$[s_n^{(k+1)}]^2 = \frac{1}{n\beta} \sum_{i=1}^n \psi^2 \left(\frac{\xi_i - \vartheta_n^{(k+1)}}{s_n^{(k)}} \right) [s_n^{(k)}]^2$$

Az algoritmus végrehajtásához szükséges az F_0 eloszlásfüggvény illetve helyettesítési értékeinek a kiszámítása.



A Gauss (normális) eloszlás

A mintaelemek eloszlásfüggvénye

$$F(x) = \int_{-\infty}^{x} \frac{1}{b\sqrt{2\pi}} \exp\left(-\frac{(u-a)^2}{2b^2}\right) du,$$

és az F_0 reprezentáns eset az a=0, b=1.

A matematikai statisztika klasszikus elmélete alapján a paraméterek legjobb becslései az átlag (ϑ) és a korrigált tapasztalati szórás (s), azaz

$$\vartheta = \frac{\sum_{i=1}^{n} \xi_i}{n}, \qquad s = \sqrt{\frac{\sum_{i=1}^{n} (\xi_i - \vartheta)^2}{n-1}}$$



Megiegyzés:

- 1. Az átlag és a korrigált tapasztalati szórás megkapható a maximum likelihood módszer alkalmazásával.
- 2. A Gauss-hálózat (papír) szemléletes ellenőrzési lehetőség, amely azt az állítást használja fel, hogy ha a ξ valószínűségi változó eloszlásfüggvénye F, akkor $F(\xi)$ egyenletes eloszlású a (0,1) intervallumon.



A lognormális eloszlás

 $f_{\xi}(x) = \left\{ \frac{1}{bx\sqrt{2\pi}} \exp\left[-\frac{1}{2b^2}(\ln x - a)^2\right], \right.$

A ξ valószínűségi változó lognormális eloszlású, ha az $\eta =$ $\ln \xi$ normális eloszlású, ahol $E(\eta) = a$ és $D^2(\eta) = b^2$. A sűrűségfüggvénye

A
$$\xi$$
 valoszínűségi valtozó lógnormális előszlásű, na az $\eta=\ln\!\xi$ normális előszlásű, ahol $E(\eta)=a$ és $D^2(\eta)=b^2$. A sűrűségfüggvénye



 $ha x \leq 0.$

Továbbá

$$E(\xi) = \exp(a + \frac{b^2}{2})$$

és

$$D^{2}(\xi) = \exp(2a + 2b^{2}) - \exp(2a + b^{2}).$$

Látható, hogy a szokásos módszerek (maximum likelihood, momentum) közvetlenül nem alkalmazhatóak, ezért a problémát visszavezetjük a logaritmikus transzformációval a normális esetre.

A lognormális eloszlás aszimmetriája következtében alkalmas például bizonyos anyagtulajdonságok külső hatások miatti megváltozásának leírására. Ezt alkalmaztuk a lognormális-hálózat (papír) elkészítésekor is.



9 A Weibull-eloszlás

A Weibull-eloszlás paramétereire többféle elterjedt jelölésrendszer van. Az eltérő jelölések használatát egyértelműen magyarázza, hogy a Weibull-eloszlás igen széles körben, a legkülönfélébb tudományterületeken alkalmazzák, valamint a paramétereknek sokféle elméleti meghatározási módja is ismeretes és az egyes megoldásoknál a változók átírása jelentős egyszerűsítéseket eredményez. Sajnos a háromparaméteres esetre nincs jól használható (numerikusan kezelhető) módszer.



Mi a következőkben az

$$F_c(x) = \begin{cases} 1 - exp(-x^c), & \text{ha } x \ge 0\\ 0, & \text{ha } x < 0 \end{cases}$$

jelölést alkalmazzuk a standard Weibull-eloszlás jelölésére. Ebből a lineáris transzformáltak eloszlása

$$F_c(\frac{x-a}{b}).$$

Tehát ez az eloszláscsalád is háromparaméteres, amelyből a c az ún. alakparaméter (típusparaméter). Viszont lényeges, hogy aszimmetrikus eloszlás.



Megjegyzés:

- 1. Az eloszlás c=1 esetén az exponenciális eloszlást, c=2 a Rayleigh eloszlás adódik, míg c=3.57 közelében az eloszlás közel szimmetrikussá válik és jól közelíti a normális eloszlást. Megfelelő paraméter választással az is elérhető, hogy a Weibull- eloszlás jól közelítse a lognormális és Γ -eloszlásokat.
- 2. A paraméterek meghatározására számos módszer létezik, de ezek egyrészt nem robusztusak, másrészt nehezen kezelhetőek. A nehezen kezelhetőségre jó példa a momemtum módszer segítségével történő paraméter meghatározás.



Ha $\xi\;a,b,c$ paraméterű Weibull-eloszlású valószínűségi változó, akkor

$$E((\xi - a)^k) = b^k \Gamma(1 + \frac{k}{c}),$$

azaz

$$\mu = E(\xi)$$

$$\sigma^2 = E(\xi - \mu)^2$$

$$\alpha_3 = E\left(\left(\frac{\xi - \mu}{\sigma}\right)^3\right)$$

Mint látható, hogy habár μ , σ^2 , α_3 egy adott mintából könnyen meghatározható, annak ellenére az egyenletrendszert nem könnyű megoldani, sőt nem is mindig van megoldása (c < 1).



Foglalkozzunk először részesetekkel, azaz feltételezzük , hogy vagy a c vagy az a értéke ismert:

Ha c ismert, akkor az előző egyenletrendszerből az a és b értéke könnyen becsülhető, viszont a becslés nem lesz robusztus, mert a várható érték megközelítésére használt átlag nem robusztus. Ellenben jó becslést ad az eloszlásfüggvényen alapuló robusztus momentumok módszere, hiszen az eloszlásfüggvény könnyen kezelhető, s a típusparaméter ismert. S így máris van robusztus módszerünk pl. az exponenciális eloszlásra, Rayleigh eloszlásra.



Ha az a ismert, akkor a mintánk illetve az eloszlásfüggvény áttranszformálható egy másik típusú eloszlásba (Gumbeleloszlás) az

$$\eta = \ln(\xi - a)$$

transzformációval, ekkor az eloszlásfüggvény

$$G(y) = 1 - exp\left(-exp\left(\frac{y-T}{s}\right)\right),$$

ahol

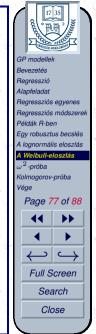
$$T = \ln b$$

a helyparaméter és

$$s = \frac{1}{\epsilon}$$

a skálaparaméter.

Ezzel nemcsak egyszerűen egy robusztus becslési lehetőséget kaptunk a Weibull-eloszlás skála- illetve



alakparaméterére, hanem egyáltalán egy egyszerű lehetőséget az eddig viszonylag bonyolult mószerekkel szemben

A következő részek a háromparaméteres esetekre vonatkoznak, azaz hogyan készíthető becslés arra az esetre, amikor mind a három paraméter ismeretlen.



MAXIMÁLIS REGRESSZIÓS EGYÜTTHATÓ MÓDSZERE

A Weibull-eloszlásfüggvényt átalakíthatjuk a következő alakra:

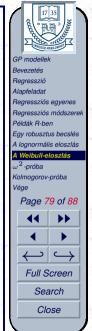
$$\ln(-\ln(1 - F(x))) = c\ln(x - a) - c\ln b.$$

Ez új változókat bevezetve

$$Y = BX + A$$

alakú lineáris összefüggés.

Ezen az elven alapszik a Weibull-hálózat (papír) is.



Az a helyparaméter megválasztásával és az F(x) valószínűséget az

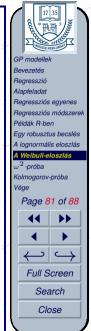
 $\frac{i-0.5}{m}$

"medián rank" összefüggésből meghatározva a egyenlet transzformációi segítségével lineáris regresszióval határozható meg a Weibull-eloszlás másik két paramétere. A mérési pontsorozat legjobb kiegyenlítését a három paraméter esetében nem lehet meghatározni. Az a helyparaméter felvételével, megváltoztatásával lehet a legiobban illeszkedő helyzethez eljutni. Az illeszkedés vizsgálatánál több más lehetőség közül a korrelációs együttható az egyik legalkalmasabb. A feladat ebben az esetben tehát úgy változtatni a helyparamétert, hogy a korrelációs együttható maximális legyen. A helyparaméter függvényében a korrelációs együttható egy konkáv függvény, amelynek maximuma egyértelmű.



A ROBUSZTUS MÓDSZER

Hasonló a maximális regressziós együttható módszeréhez, azonban itt felhasználva a b és c paraméterekre a robusztus becslési módszert az ω^2 statisztika értékét minimalizáljuk.



Legyen a $\xi_1, \xi_2, \ldots, \xi_n$ mintához tartozó rendezett minta ${\xi_1}^\star, {\xi_2}^\star, \ldots, {\xi_n}^\star$. Továbbá legyen ${\xi_0}^\star = -\infty$ és ${\xi_{n+1}}^\star = +\infty$, ekkor az empirikus eloszlásfüggvény

$$F_n^*(x) = \frac{k}{n}$$
, ha $\xi_k^* < x < \xi_{k+1}^*$,

ahol k = 0, 1, ..., n.

Az ${F_n}^\star(x)$ -nek a feltételezett F(x)-től vett eltérése mértékéül az

$$\omega_n^2 = n \int_{-\infty}^{+\infty} (F(x) - F_n^*(x))^2 dF(x)$$

mennyiséget használják a következő Mises-Szmirnov tétel alapján.



Tétel:

Tetszőleges F(x) folytonos eloszlásfüggvényű ξ valószínűségi változóra, minden x>0 esetén igaz, hogy

$$\lim_{n \to \infty} P(\omega_n^2 < x) = a_1(x),$$

ahol az $a_1(x)$ függvény nem függ ξ -től.

Megjegyzés:

1. Az ω_n^2 statisztikát a következőképpen lehet meghatározni az F(x) eloszlásfüggvény és a minta segítségével:

$${\omega_n}^2 = \frac{1}{12n} + \sum_{k=1}^n \left(F({\xi_k}^\star) - \frac{k - 0.5}{n} \right)^2.$$

2. Az $a_1(x)$ eloszlásfüggvénynek csak a karakterisztikus függvénye adható meg közvetlenül használható formában,



ezért a próba alkalmazásához szükséges a következő táblázat:

3. Az ω^2 -próba: Rögzítünk egy p megbízhatósági szintet és az

$$a_1(x_p) = p$$

egyenletből kiszámítjuk a megfelelő x_p kvantilis értékét illetve az előző segítségével ellenőrizzük, hogy a feltételezett F(x) eloszlásfüggvény és az $F_n^\star(x)$ empirikus eloszlásfüggvényből kiszámított ω_n^2 milyen x_p -hez viszonyítva. Ha $\omega_n^2 > x_p$, akkor a feltevésünk nem fogadható el.

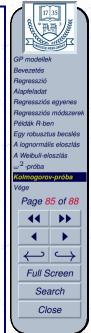


11 Kolmogorov-próba

A Kolmogorov-próba az előző ω^2 -próbához hasonlóan az empirikus és az elméleti eloszlás eltérését vizsgálja. Felhasználva az előző szakasz jelöléseit a módszer a következő: határozzuk meg a

$$D = \sup_{x} |F_n^{\star}(x) - F(x)|$$

értékét. A D eloszlása az előzőhöz hasonlóan független Ftől, így a D értéke alapján az illeszkedésvizsgálat könnyen eldönthető.



Köszönöm a figyelmet!



References

- [1] A. C. Allen: Probability, Statistics and Queueing Theory, With Computer Applications, Academic Press, New York, 2003. ISBN-13: 978-0120510504
- [2] Deák I.: Véletlenszámgenerátorok és alkalmazásaik, Akadémiai Kiadó, Budapest, 1986.
- [FR11] Fegyverneki Sándor, Raisz Péter: Sztochasztikus modellezés, elektronikus jegyzet, 2011, TÁ-MOP 4.1.2-08/1/A-2009-0001 project, https://www.uni-miskolc.hu/~ matfs/
- [FS11] Fegyverneki Sándor: Valószínűség-számítás és matematikai statisztika, elektronikus jegyzet, Kempelen Farkas elktronikus könyvtár, 2011,



TÁMOP 4.1.2-08/1/A-2009-0001 project, https://www.uni-miskolc.hu/~matfs/

[FE78] W. Feller: Bevezetés a valószínűségszámításba és alkalmazásaiba, Műszaki Könyvkiadó, Budapest, 1978.

[3] I.M. Szobol: A Monte-Carlo módszerek alapjai, Műszaki Könyvkiadó, Budapest, 1981.

